



# Forest Fires Detection

---

Faculty of Mathematics and Computer Science  
Babeș-Bolyai University



Firefighters Team  
AI Models in Climate Change

# Context


- Pădurile jocă un rol crucial în păstrarea echilibrului biologic al planetei, iar incendiile forestiere pot fi catastrofice, având impacte severe și diverse la nivelul mediului înconjurător, al economiei și al vieților omenești. Printre cele mai serioase consecințe ale incendiilor se numără încălzirea globală, pierderea biodiversității și deteriorarea habitatului natural. Predicția și detectarea incendiilor forestiere într-un stadiu incipient sunt vitale pentru atenuarea daunelor provocate de incendii și minimizarea acțiunilor necesare pentru stingerea flăcărilor.





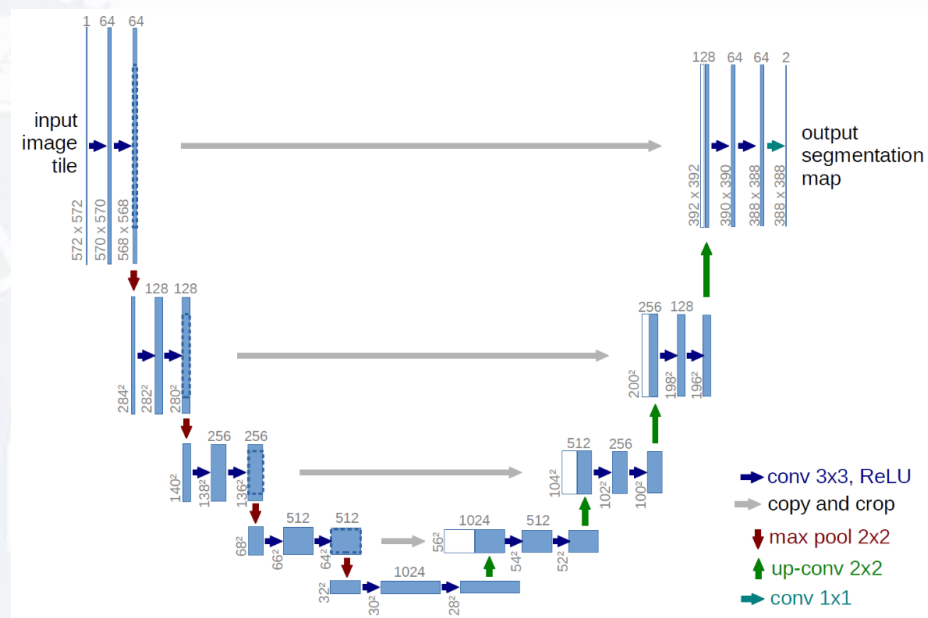
# Abordări

Rețele neuronale convoluționale (CNN) sunt una dintre cele mai frecvent utilizate metode DL în acest domeniu, deoarece pot învăța automat caracteristici din imagini din satelit, fotografii aeriene sau imagini termice, putând utiliza aceste caracteristici pentru a efectua diverse sarcini, cum ar fi detectarea și segmentarea incendiilor.



# Abordări

Pentru segmentare, unul dintre cele mai frecvent folosite modele este U-Net, o rețea neuronală convolutivă al cărui nume este inspirat de forma de U (adică din 2 componente, partea de feature extraction (extragerea de caracteristici), în care dimensiunile se reduc, dar numărul de canale crește, și partea de mask construction (construirea măștii), în care se folosește și informația extrasă de la anumite dimensiuni.



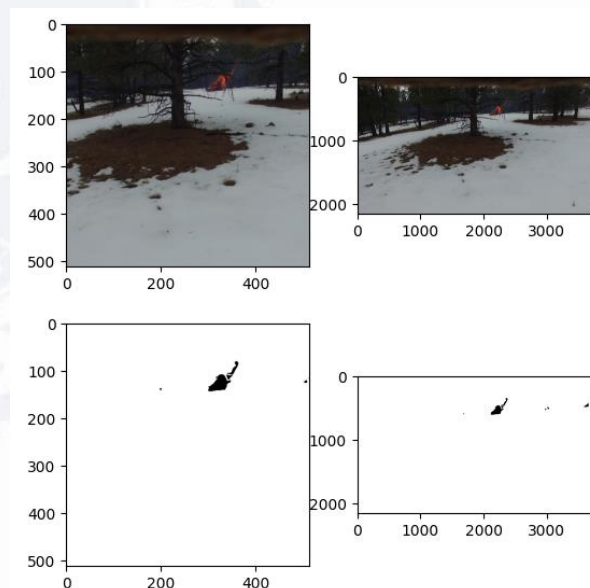

# Set de date

FLAME (*Fire Luminosity Airborne-based Machine learning Evaluation*) a fost colectat utilizând drone în timpul unei arderi controlate din Arizona, SUA. În setul de antrenare există aproximativ 39.375 de imagini etichetate în “fire” sau “non-fire”, iar în cel de testare sunt etichetate 8.617 cadre. 2003 cadre sunt considerate pentru segmentarea incendiilor și astfel, 2.003 măști sunt generate în scopul datelor de referință (Ground Truth) cu adnotări la nivel de pixel.



# Preprocesarea datelor

Pentru preprocesare, imaginilor le-a fost efectuat un central crop și o redimensionare pe dimensiunea 128, pentru a putea realiza cât mai multe experimente pentru a stabili cei mai importanți hyperparameters. Observăm din histograma cu distribuția pixelilor (pentru rezoluția 512) că este una destul de potrivită pentru task-ul nostru.

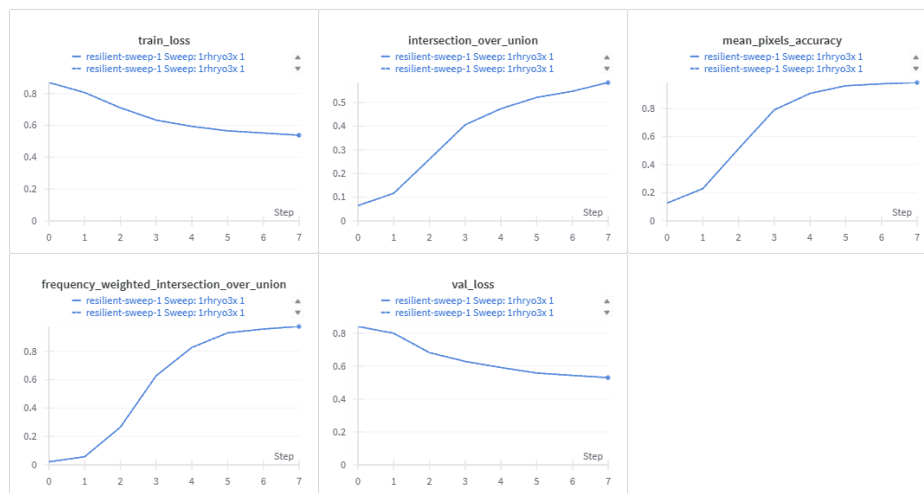


# Experiment 1

Deși experimentul 1 a fost realizat pe o rezoluție mică a imaginilor, se pare că se obțin rezultate destul de bune, atât pe setul de antrenare, cât și pe setul de validare (și se poate observa și din imaginile realizate pe setul de validare că algoritmul pare să detecteze corect locația focului). În plus, se mai pare că după 8 epoci algoritmul pare că începe să convergă, deci antrenamentul pentru următoarele experimente nu ar trebui să dureze mult mai mult de 12-16 epoci.

```
=== Run Configuration ===  
device = device(type='cuda')  
seed = 0  
resolution = 128  
num_epochs = 8  
batch_size = 32  
in_channels = 3  
out_channels = 1  
learning_rate = 1e-05
```

## Results






# Experiment 1

Imagine reala



Masca de  
segmentare reala




Masca de segmentare prezisa de model

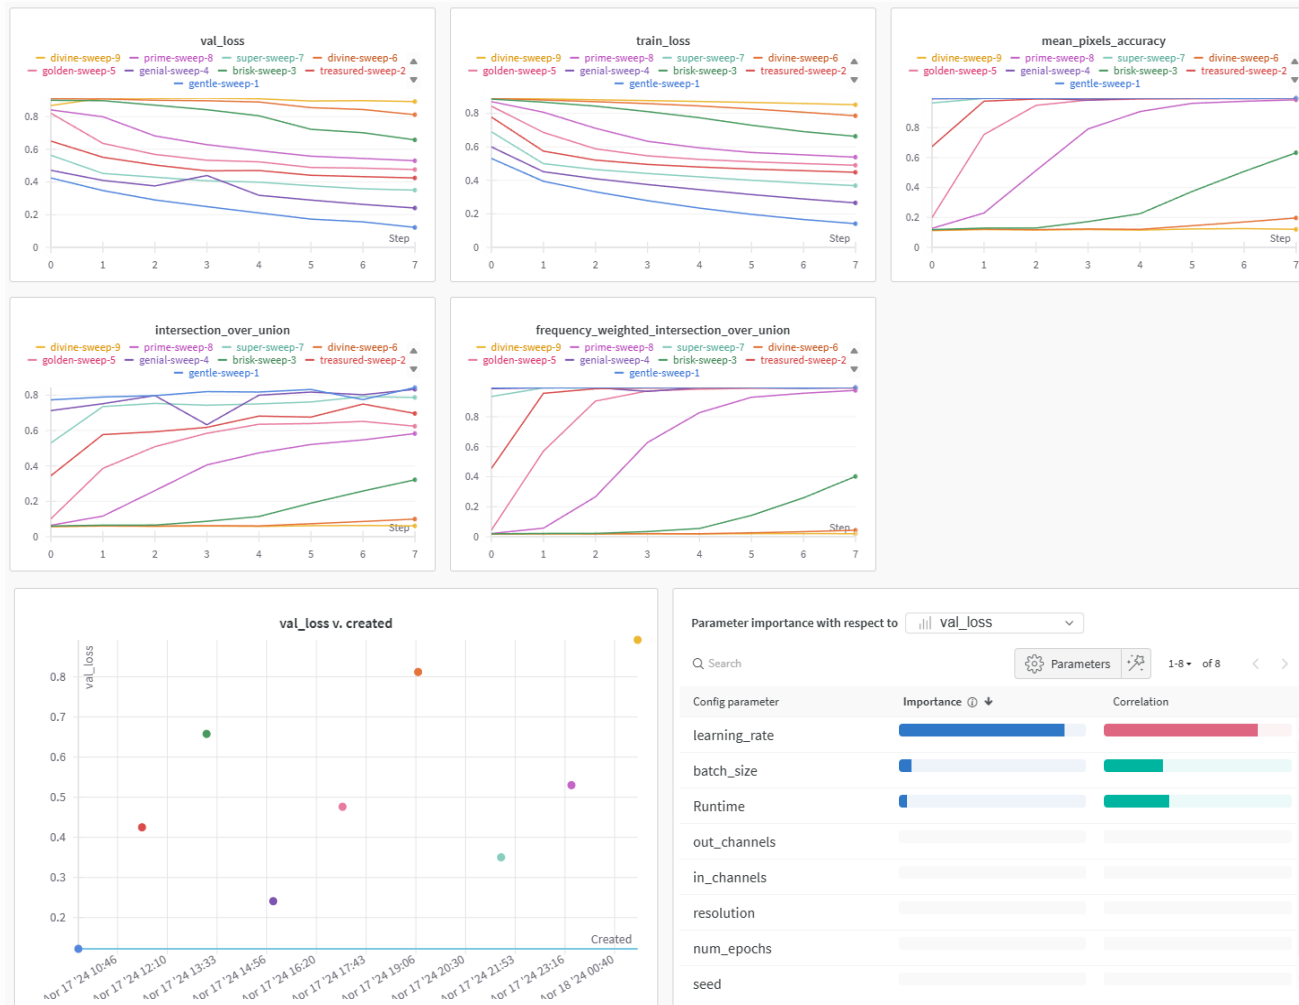


## Experiment 2

La cel de-al doilea experiment am urmărit modificarea comportamentului metricilor în funcție de modificarea unor parametri ai algoritmului. Ambele experimente au păstrat rezoluția imaginii la dimensiuni de 128x128 pixeli, singurele modificări le-am adus parametrilor *learning rate* și *batch size*. În cadrul experimentului 2, cea mai bună rulare (care a obținut cele mai bune valori ale metricilor de evaluare) s-a obținut pentru *batch\_size*=8 și *learning\_rate* =  $10^{-3}$ . S-a observat că la creșterea *batch\_size* sau la micșorarea *learning rate*, performanța algoritmului a scăzut.



# Experiment 2




## Experiment 2

Imagine reala



Masca de  
segmentare reala



Masca de segmentare prezisa de cel mai bun model

# Comparație între experimente

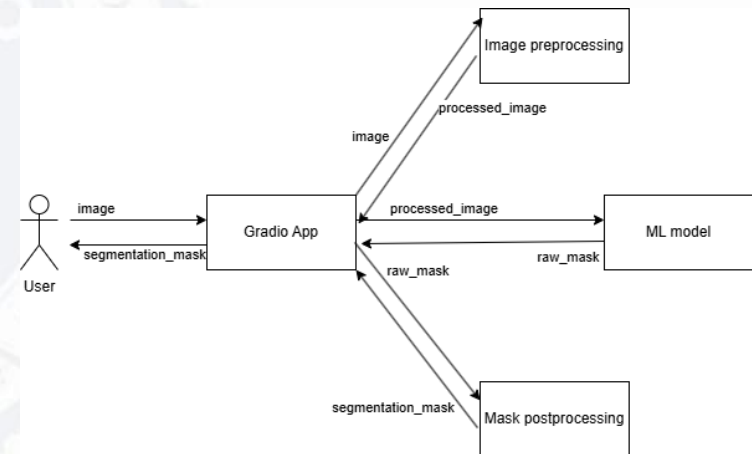
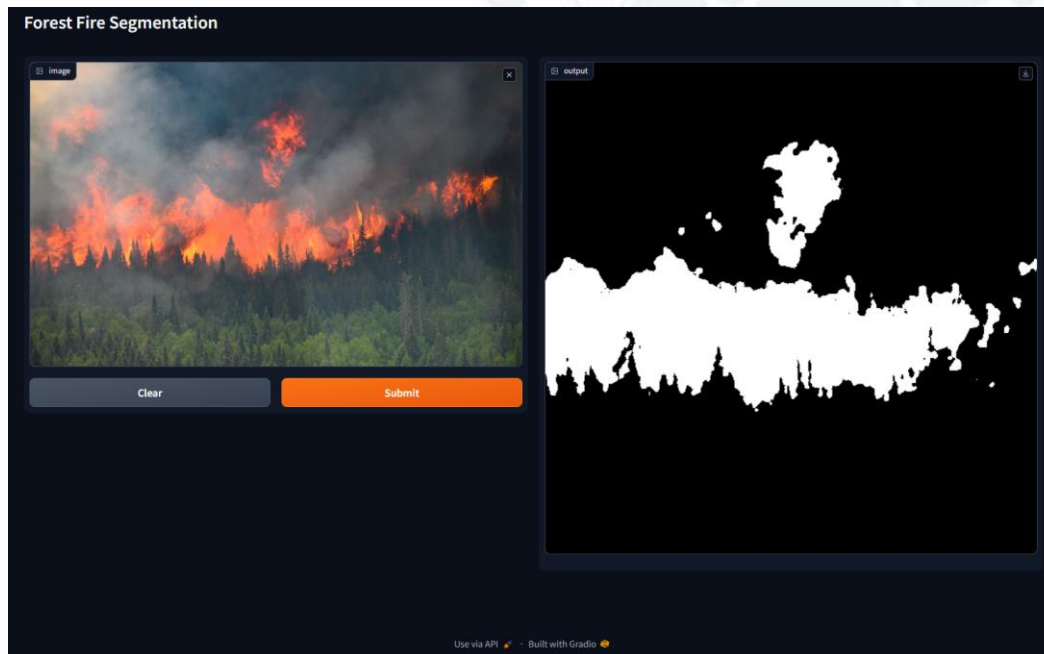
	<i><b>Train Loss</b></i>	<i><b>IoU</b></i>	<i><b>MPA</b></i>	<i><b>fwIoU</b></i>	<i><b>Val Loss</b></i>
1	0.5383	0.5843	0.9861	0.9758	0.5301
2	<b>0.1415</b>	<b>0.8436</b>	<b>0.9974</b>	<b>0.9952</b>	<b>0.1222</b>
Original paper		0.7817	0.9199		
Most recent paper		0.848	0.931		

☆ Rezultatul de la paper-ul original și cel mai recent sunt calculate pe rezoluția originală, pentru experimentele 1 și 2 este realizată pe rezoluția mai mică



# Demo

Aplicația a fost dezvoltată folosind librăria Gradio. Utilizatorul va introduce imaginea și va apăsa pe butonul de “Submit”, iar aplicația va prezice masca de segmentare corespunzătoare.



# Concluzii şi posibile îmbunătăţiri

În cadrul proiectului dezvoltat, am utilizat arhitectura U-Net pentru realizarea segmentării şi a detecţiei incendiilor din imagini. Cele două experimente ne arată importanţa alegerii parametrilor potriviţi pentru algoritmi în vederea îmbunătăţirii performanţei acestora. Deşi metricile obţinute sunt satisfăcătoare, o şi posibilă direcţie de dezvoltare ar fi utilizarea unei arhitecturi mai performante pentru U-Net precum Attention U-Net şi compararea rezultatelor cu cele obţinute în cadrul experimentelor, pentru a analiza modul în care se modifică acurateţea obţinută.



Mulțumim pentru atenție!